

DenoiseRL 近期改进与后续计划

动态难度控制、跨任务验证与噪声来源分析

核心思路

让噪声强度随单个样本的实际表现变化，同时通过对照实验判断这种额外复杂度是否真正优于固定 $\rho=0.2$ 。

1 动态控制机制

近期，我们在 DenoiseRL 中引入了动态控制机制，不再为所有训练样本固定使用同一个噪声比例 ρ ，而是为每个样本单独维护和调整 ρ 。 ρ 表示保留错误推理前缀的比例： ρ 越大，模型需要从越长的错误前缀中恢复，任务也越困难。

对于样本 i ，根据当前 rollout 的平均正确率更新噪声比例：

$$\rho_i \leftarrow \text{clip}(\rho_i + \alpha(A_i - A_{\text{target}}), \rho_{\min}, \rho_{\max})$$

当正确率高于目标值时，系统增大 ρ ，为该样本加入更强的噪声；当正确率低于目标值时，则减小 ρ ，降低恢复难度。

系统还会记录每个样本最近一段时间的 ρ 变化。当变化趋势趋于稳定时，该样本会被新的训练样本替换；新样本继承当前 batch 更新后的平均 ρ 。因此，这一过程可以看作一种按样本难度自适应的 curriculum learning。

优点 · 细粒度

不同样本可以根据自身难度获得不同强度的噪声，避免统一的 ρ 对简单样本过弱、对困难样本过强。

缺点 · 多样性受限

样本在达到稳定状态前会被重复采样和训练，短时间内可见的训练样本数量有限，可能造成重复并带来一定的过拟合风险。

2 补充实验

在 rebuttal 期间，我们已经补充了以下实验：

- ALFWorld 实验：在 ALFWorld 上测试动态控制方案，用于观察该机制能否从数学推理任务迁移到交互式决策和 agent 场景。
- 不同 noise 来源：对比 Pre-RL Self (RL 前的模型自身生成)、Small Model (小模型生成) 和 Random Token (随机 token) 三种噪声来源，以分析性能变化究竟来自结构化的错误推理，还是仅仅来自一般性的输入扰动。

3 后续判断与计划

动态控制在直觉上能够让噪声难度更贴合模型当前能力，但它并不一定会带来稳定的性能提升。后续将重点比较动态控制与固定 $p=0.2$ 方案，并尽量保持训练数据、计算量和评测设置一致。

最终判断标准

如果动态控制没有取得稳定且可复现的收益，我们将继续采用更简单、稳定的固定 $p=0.2$ 方案。ALFWorld 和不同 noise 来源实验已在 rebuttal 期间补充完成，接下来主要根据实验结果判断动态控制是否值得保留。